

PoC: parsing do boletim do INEA

Prova de que é possível acessar e extrair, de forma estruturada, os dados de balneabilidade das praias publicados pelo INEA. Item do quadro da Sprint 3: “PoC: parsing do boletim do INEA”.

Este é o boletim que a `logica-recomendacao` (ver `Sprint-3/Vitor-Rocha/logica-recomendacao/logica-recomendacao.md`, PR #12) consome como `status_inea`: o boletim de balneabilidade (próprio/impróprio por ponto de praia), não o Sistema de Alerta de Cheias (que é sobre nível de rio/enchente, domínio errado para um app sobre ir ou não à praia).

Fonte usada

Página oficial do INEA sobre o tema: <https://www.inea.rj.gov.br/ar-agua-e-solo/balneabilidade-das-praias/>

Essa página publica o boletim estadual atual só como PDF semanal (por exemplo

https://www.inea.rj.gov.br/wp-content/uploads/2026/07/Site-Boletim-de-Balneabilidade-do-Estado-do-RJ_03.07.2026_v2.pdf). O status por ponto de coleta nesse PDF é desenhado como marcador colorido em cima de um mapa (imagem), não como texto ou tabela: a camada de texto do PDF só traz título, sumário e nomes de praias/página, sem os status. Não dá para extrair “próprio/impróprio” por ponto desse PDF sem OCR/reconhecimento de imagem, o que foge do escopo de um PoC de parsing estruturado.

A mesma classificação que o INEA publica para as praias de Niterói também está disponível como JSON estruturado, através do portal de geoprocessamento da Prefeitura de Niterói, numa camada ArcGIS chamada “Boletins de Balneabilidade - INEA”:

- Endpoint usado:

`https://geo.niteroi.rj.gov.br/arcgis/rest/services/Aplicacoes/AplicacaoINEA/FeatureServer/0/query`

Essa camada é alimentada com os mesmos dados que o INEA classifica e divulga (fonte primária), só que republicados pela prefeitura em formato de API GIS em vez de PDF. `parse_boletim_inea.py` usa esse endpoint.

O que o parser extrai

`parse_boletim_inea.py` consulta a camada ArcGIS com `returnDistinctValues` e devolve um objeto por ponto de monitoramento:

- `praia`: nome da praia
- `municipio`: fixo em “Niteroi” (ver Cobertura abaixo)
- `codigo_ponto`: código do ponto de coleta usado pelo INEA (ex.: `IC000`)
- `localizacao`: descrição textual do local do ponto na praia
- `status`: `propria` ou `impropria`
- `data_publicacao_boletim`: data do boletim a que esse status se refere

Um exemplo real de saída está em `sample-output.json`.

Como rodar

```
python3 parse_boletim_inea.py
```

`--out arquivo.json` grava em arquivo em vez de imprimir no terminal.

Sem dependências externas: usa só a biblioteca padrão do Python 3 (`urllib`, `json`, `ssl`).

Ressalvas

Cobertura geográfica: essa camada cobre só as praias de Niterói (29 pontos de monitoramento). O boletim estadual completo do INEA cobre 291 pontos em 197 praias em 19 municípios, mas só achamos essa API estruturada para Niterói; não confirmamos se outros municípios do estado publicam uma camada GIS equivalente.

Dado desatualizado: todos os pontos retornam `data_publicacao_boletim` igual a `2023-12-11`, então essa camada não vem sendo atualizada desde então (o boletim semanal real do INEA é publicado toda semana). Para virar produção, seria necessário confirmar com a prefeitura de Niterói ou com o INEA se essa camada ainda é mantida, ou trocar por uma fonte que receba as atualizações semanais.

Certificado TLS incompleto: o servidor `geo.niteroi.rj.gov.br` não envia a cadeia de certificados intermediária, então uma verificação TLS padrão falha com “unable to verify the first certificate” (mesmo problema encontrado antes no domínio do INEA). O script contorna isso desabilitando a verificação de certificado só para esse host. Para um PoC isso é aceitável, mas antes de produção vale revisar a cadeia de certificados ou fixar o certificado esperado.

Sem autenticação nem rate limit visível: o endpoint é público e não pede login, mas não é uma API oficial documentada do INEA, então vale evitar uso intenso por respeito à infraestrutura da prefeitura.

Nomenclatura: os valores de status (`Própria` / `Imprópria`) são os termos usados pelo próprio INEA, normalizados aqui para `propria` / `impropria`.